

Um estudo sobre os algoritmos genéticos

Gustavo Fernandes de Barros¹, Wladimir Araújo Tavares¹

¹Universidade Federal do Ceará (UFC) - Campus Quixadá
Av. Jose de Freitas Queiroz, 5003 – Cedro, 63902-580 - Quixadá-CE

gustavofer14@alu.ufc.br, wladimirufc@gmail.com

Abstract. *Genetic algorithms are mathematical models based at evolutive biology concepts, often used in optimization of problems to generate a set of solutions that adapt evolutionarily to get what would be the closest ideal solution for a determined problem. This article has as its objective dissertation about these algorithms, about their functionality and characteristics that differentiate them from common algorithms.*

Keywords: *Algorithms. Byology. Optimization. Problems*

Resumo. *Algoritmos genéticos são modelos matemáticos baseados em conceitos de biologia evolutiva, frequentemente utilizados na otimização de problemas ao gerar um conjunto de soluções que se adaptam evolutivamente até obter o que seria a solução ideal mais próxima para determinado problema. O presente artigo tem como objetivo dissertar acerca destes algoritmos, adentrando sobre seu funcionamento e características que os diferem de algoritmos comuns.*

Palavras-chave: *Algoritmos. Biologia. Otimização. Problemas*

1. Introdução

Geralmente tarefas de busca e otimização possuem alguns padrões de execução, tais como um espaço de busca, onde estão todas as possibilidades de soluções para o problema proposto, e funções de avaliação, que tem a utilidade de avaliar as possíveis soluções do espaço de busca. Esses métodos tradicionais geralmente tomam para si um candidato de forma iterativa, e nele aplicam algumas heurísticas associadas ao problema até que se encontre a solução esperada, processo este que é bastante útil em várias aplicações.

Entretanto, técnicas de computação evolucionária (baseada em populações) são capazes de operar sobre candidatos paralelamente, assim fazendo a busca em diferentes áreas do espaço de busca (muito semelhante a uma árvore binária), o que torna os algoritmos genéticos muito eficientes na busca de soluções ótimas, ou aproximadamente ótimas em uma grande variedade de problemas, visto que não possuem as limitações encontradas nos métodos de busca tradicionais, além de ser uma operação muito elegante, pois são baseados na biologia evolutiva e também são capazes de convergir para soluções ótimas, ou aproximadamente ótimas em níveis globais.

Neste artigo, vamos apresentar um estudo sobre os algoritmos genéticos clássicos. Na Seção 2, apresentaremos os conceitos principais relacionados com os algoritmos genéticos. Na Seção 3, apresentamos os principais procedimentos dos algoritmos genéticos. E por fim, na seção 4, tecemos algumas considerações finais sobre os principais desafios no desenvolvimento de algoritmos genéticos mais eficientes.

2. Fundamentação Teórica

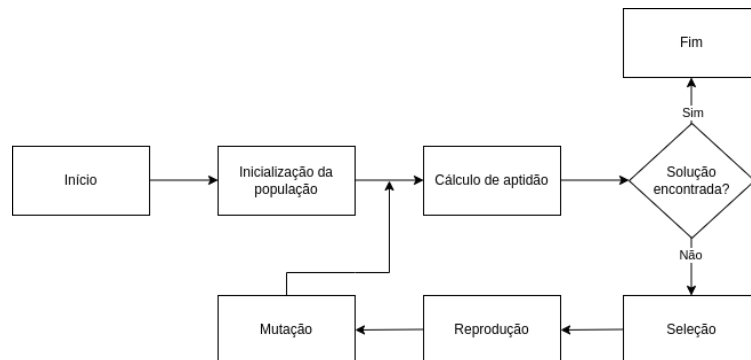
Algoritmos genéticos são basicamente modelos que seguem representativamente os processos da teoria moderna da evolução, gerando soluções que podem ser perpetuadas se possuírem as características necessárias ou podem ser extintas caso contrário. Imaginar como estes conceitos evolucionistas se aplicam na computação pode ser ligeiramente difícil, por isso é necessário que se entenda o que cada componente envolvido neste processo significa do ponto de vista computacional.

Conceitos	Biologia	Computação
Aptidão	O quão bom um genótipo é em deixar descendentes para a próxima geração	O quão próximo uma entrada está da solução do problema
Cromossomo (Indivíduo)	Corpúsculos compactos que carregam a informação genética	Cadeia de bits (binário, inteiro ou real) que representa uma possível solução para o problema
Cruzamento	Relação entre dois organismos para perpetuar suas características	Mistura de duas cadeias de bits para gerar novas possíveis soluções
Gene	Segmento de uma molécula de DNA	Bits usados na formação de uma cadeia para representar presença ou ausência de características
Geração	Indivíduos que estão no mesmo estágio de descendência de um ancestral comum	Nova leva de cadeias de bits gerados a cada iteração do algoritmo
População	Conjunto de indivíduos de uma mesma espécie que habitam numa determinada área	Conjunto de cadeias de bits no espaço de busca da solução
Mutação	Mudanças no material genético de um organismo	Mudanças nos bits de uma cadeia
Seleção	Organismos mais aptos a viver em determinado ambiente são selecionados	As cadeias de bits mais próximas da solução do problema proposto são selecionados

Esta tabela pode ser usada para sanar quaisquer dúvidas em relação aos procedimentos envolvidos nos processos de um algoritmo genético e seus significados.


3. Procedimentos

O funcionamento de um algoritmo genético segue uma sequência de procedimentos que simulam explicitamente uma espécie de seleção natural entre os cromossomos (cadeias de bits) de uma população (espaço de busca da solução). Essa é uma sequência recursiva cuja chamada externa acontece quando há uma geração cujos seus cromossomos correspondam a uma solução ideal para o problema.



3.1. Geração da População

É gerada uma população com um determinado número de indivíduos, cada um com seus respectivos genes e com determinadas chances de serem a solução para o problema.




3.2. Cálculo de Aptidão

Cada indivíduo de uma população é avaliado separadamente de acordo com os parâmetros do problema. Através deste cálculo é definido o quão apto um determinado indivíduo está para participar da seleção ou para ser considerado uma solução viável.

3.3. Seleção Natural


Após o cálculo de aptidão, caso não se tenha achado a solução desejada, os indivíduos que obtiveram os melhores resultados são separados para os demais processos, enquanto os demais indivíduos são descartados. Nesta fase os indivíduos têm a probabilidade de serem escolhidos proporcionalmente ao seu cálculo de aptidão em um mecanismo semelhante ao de uma roleta, chamado de amostragem universal estocástica.

Indivíduo	Aptidão	Aptidão
S_i	$f(S_i)$	Relativa
S1 10110	2.23	0.14
S2 11000	7.27	0.47
S3 11110	1.05	0.07
S4 01001	3.35	0.21
S5 00110	1.69	0.11



3.4. Cruzamento

Os indivíduos selecionados na fase anterior são selecionados em pares, onde cada indivíduo vai realizar um “cruzamento” com seu par, o que basicamente significa que os cromossomos de cada indivíduo são particionados em um determinado ponto e novos cromossomos são gerados, permutando-se a metade inicial de um cromossomo com a metade final do outro.



3.5. Mutação

A mutação ocorre para manter a diversidade entre as futuras populações, garantindo uma maior varredura do espaço de busca das soluções. A mutação acontece quando altera-se aleatoriamente o valor do gene de um indivíduo, também escolhido randomicamente.

Before Mutation

A5 1 1 1 0 0 0

After Mutation

A5 1 1 0 1 1 0

Passado todas as etapas, o algoritmo é executado novamente de forma recursiva, parando somente quando uma determinada geração passar nos cálculos de aptidão propostos, assim sendo considerada uma solução ideal para o problema.

4. Considerações Finais

Apesar das vantagens e da grande flexibilidade dos algoritmos genéticos, vários desafios ainda precisam ser resolvidos para que os algoritmos genéticos alcancem melhores resultados, entre eles:

- Seleção de uma população inicial
- Convergência prematura
- Refinamento da taxa de mutação e crossover
- Seleção do esquema adequado de codificação.

Além disso, na literatura, podemos encontrar extensões dos algoritmos genéticos como o algoritmo genético de chaves aleatórias (ou RKGA, do inglês random-key genetic algorithms)(Bean, 1994) e os algoritmos genéticos de chaves aleatórias viciadas (ou BRKGA, do inglês, based random-key genetic algorithm)(Gonçalves; Resende, 2011). Essas extensões estão conseguindo bons resultados em várias aplicações.

O estudo apresentado neste artigo é um estudo inicial para o uso dos algoritmos genéticos. Esperamos aprofundar esse estudo para a resolução de algum problema complexo do mundo real.

Uma implementação simples e intuitiva de um algoritmo genético pode ser encontrada [aqui](#).

Referências

M. Mitchell, *An Introduction to Genetic Algorithms*. MIT Press, 1996.

KATOCH, Sourabh; CHAUHAN, Sumit Singh; KUMAR, Vijay. A review on genetic algorithm: past, present, and future. **Multimedia Tools and Applications**, v. 80, n. 5, p. 8091-8126, 2021.

DORIGO, Marco; STÜTZLE, Thomas. Ant colony optimization: overview and recent advances. **Handbook of metaheuristics**, p. 311-351, 2019.

SENGUPTA, Saptarshi; BASAK, Sanchita; PETERS, Richard Alan. Particle Swarm Optimization: A survey of historical and recent developments with hybridization perspectives. **Machine Learning and Knowledge Extraction**, v. 1, n. 1, p. 157-191, 2018.

BEAN, James C. Genetic algorithms and random keys for sequencing and optimization. **ORSA journal on computing**, v. 6, n. 2, p. 154-160, 1994.

GONÇALVES, José Fernando; RESENDE, Mauricio GC. Biased random-key genetic algorithms for combinatorial optimization. **Journal of Heuristics**, v. 17, n. 5, p. 487-525, 2011.